GEM DADOS

Documentação Técnica

Plataforma de dados, infraestrutura e operação

Descrição consolidada da infraestrutura, pipelines, views analíticas e dashboard Looker Studio.

GEM Dados - Grupo de Estudos e Mentoria em Dados

Controle do documento

Campo	Valor
Versão	1.4
Data de referência	24 de setembro de 2026
Público	Time técnico, mantenedores, mentores e novos colaboradores
Escopo	Infraestrutura GCP, pipelines, views analíticas no BigQuery e dashboard Looker Studio

Critério

O conteúdo descreve os recursos provisionados em nuvem, repositórios de código, views analíticas SQL no BigQuery e a integração com a camada de visualização no Looker Studio em 24 de setembro de 2026.

Contents

1 Objetivo e escopo 3

2 Termos essenciais 3

3 Arquitetura registrada no código 3
- 3.1 Componentes . . . 3
- 3.2 Fluxo da arquitetura de ponta a ponta . . . 4
- 3.3 Ambientes . . . 4

4 Mapa dos repositórios 4

5 Infraestrutura - cloud_iac 4
- 5.1 Diretórios de configuração . . . 4
- 5.2 Módulos Terraform presentes no repositório . . . 5
- 5.3 Recursos definidos por ambiente . . . 5
- 5.4 Valores dos ambientes . . . 6
- 5.5 Esteiras de infraestrutura . . . 6
  - 5.5.1 Pull request . . . 6
  - 5.5.2 Push na branch do ambiente . . . 6

6 Ingestão - data_ingestion 6
- 6.1 Aplicação HTTP . . . 6
- 6.2 Jobs de ingestão registrados . . . 6
- 6.3 Variáveis lidas pela aplicação . . . 7
- 6.4 Esteira de deploy . . . 7

7 Modelagem e Views Analíticas 7
- 7.1 Configuração Dataform . . . 7
- 7.2 Declarações de fontes . . . 7
- 7.3 Camada de staging (definitions/staging) . . . 8
- 7.4 Camada de marts (definitions/marts) . . . 8
- 7.5 Testes de qualidade e integridade . . . 8
- 7.6 Views analíticas no BigQuery (gem-dados-lake-stg.staging) . . . 8
- 7.7 Decisão técnica: migração dos cálculos para SQL . . . 9

8 Camada de visualização - Looker Studio 9
- 8.1 Conexões e origens do dashboard . . . 9
- 8.2 Estrutura de páginas e controles . . . 9

9 Operação registrada 9

9.1 Fluxo Git descrito nos READMEs 10
9.2 Pontos de observação dos serviços definidos 10

10 Controles de segurança versionados **10**

11 Inventário dos componentes **11**

12 Localização dos componentes **11**

1 Objetivo e escopo

A plataforma de dados em nuvem GEM Dados cobre infraestrutura como código, serviço de ingestão conteinerizado, modelagem analítica no BigQuery e camada de visualização no Looker Studio.

Este documento registra:

- a responsabilidade de cada repositório e camada;
- os recursos de infraestrutura definidos para os ambientes;
- as rotas, funções e variáveis do serviço de ingestão;
- as declarações de fontes e tabelas staging;
- as views analíticas SQL que centralizam as regras de cálculo;
- a arquitetura de consumo do dashboard Looker Studio;
- as esteiras de validação, deploy e controles de segurança.

2 Termos essenciais

Termo	Significado neste projeto
GCP	Google Cloud Platform, conjunto de serviços em nuvem usado pela solução.
GCS	Google Cloud Storage, armazenamento de objetos usado para a landing zone.
BigQuery	Banco analítico que hospeda os datasets raw, staging e marts.
Cloud Run	Serviço que executa o container Python de ingestão.
Dataform	Serviço que compila e executa as definições SQLX no BigQuery.
Terraform	Ferramenta de infraestrutura como código usada em cloud_iac.
Cloud Build	Serviço de CI/CD que valida, constrói e publica mudanças.
IAM	Controle de identidades e permissões dos recursos do GCP.
Looker Studio	Ferramenta de BI que provê o dashboard de acompanhamento de mentorados.
Views analíticas	Camada SQL no BigQuery que centraliza regras e métricas calculadas.

3 Arquitetura registrada no código

3.1 Componentes

1. O repositório cloud_iac define recursos e permissões no GCP com Terraform.
2. O repositório data_ingestion contém uma aplicação Flask configurada para Cloud Run.
3. O repositório data_models registra dez fontes raw no Dataform.
4. Cloud Build, Cloud Workflows e Cloud Scheduler conectam deploy e execução conforme os arquivos Terraform e YAML versionados.
5. Views SQL analíticas intermediárias consolidam as regras de negócio sobre a camada staging.

6. O Looker Studio consome as views e tabelas de staging para alimentar o Dashboard de Acompanhamento de Mentorados.

3.2 Fluxo da arquitetura de ponta a ponta

Staging (BigQuery) -> Views SQL Analíticas -> Looker Studio -> Dashboard

3.3 Ambientes

Ambiente	Projeto GCP	Branch	Finalidade registrada
Staging	gem-dados-lake-stg	stg	Ambiente de validação integrado e origem do dashboard.
Produção	gem-dados-lake-prd	main	Ambiente associado à branch principal.

Cada ambiente possui diretório Terraform, backend de state, projeto GCP e valores próprios. A promoção descrita nos READMEs ocorre de stg para main por pull request.

4 Mapa dos repositórios

Repositório	Tecnologia	Responsabilidade	Artefato produzido
cloud_iac	Terraform e Cloud Build	Define recursos, IAM, conexões e esteiras no GCP.	Plano e aplicação de infraestrutura.
data_ingestion	Python, Flask e Cloud Run	Expõe rotas HTTP e executa jobs de ingestão.	Imagem Docker para Cloud Run.
data_models	SQLX e Dataform	Declara fontes e transforma dados no BigQuery.	Views de staging e tabelas de marts.

5 Infraestrutura - cloud_iac

5.1 Diretórios de configuração

Diretório	Conteúdo versionado
bootstrap/	Bucket de state, conta terraform-ci, Secret Manager, conexão GitHub 2nd gen e triggers iniciais.
org/	Tag de governança environment, valores de ambiente e permissão tagUser.
envs/stg/	Composição Terraform do projeto gem-dados-lake-stg.
envs/prd/	Composição Terraform do projeto gem-dados-lake-prd.
modules/	Módulos Terraform chamados pelos ambientes e pelo bootstrap.

5.2 Módulos Terraform presentes no repositório

Módulo	Recurso principal	Configuração encontrada
project_baseline	APIs e tag de ambiente	Habilita APIs e pode vincular a tag de governança ao projeto.
gcs_bucket	Bucket GCS	Acesso uniforme, prevenção de acesso público, versionamento e lifecycle.
bigquery_dataset	Dataset BigQuery	Localização, descrição, labels e controles de destruição.
artifact_registry	Repositório Docker	Repositório usado para a imagem de ingestão.
cloud_run_service	Serviço Cloud Run v2	Imagem, conta de serviço, recursos, env vars, secrets e invocadores.
dataform_repository	Repositório Dataform	URL Git, branch, token e banco padrão.
dataform_orchestration	Workflow e Scheduler	Conta orquestradora, permissões, Workflow e agendamento.
ingestion_orchestration	Workflow e Scheduler	Orquestração da ingestão conteinerizada antes do Dataform.
cloudbuild_connection	Conexão GitHub 2nd gen	Conexão e registro de repositório no Cloud Build.
cloudbuild_trigger	Trigger Cloud Build	Evento push ou pull request, branch, arquivo YAML e substituições.

5.3 Recursos definidos por ambiente

Os arquivos envs/stg/main.tf e envs/prd/main.tf possuem a mesma estrutura. Neles estão definidos:

- habilitação de APIs e vínculo da tag de ambiente;
- conta de serviço data-ingestion e seus vínculos IAM;
- datasets BigQuery raw, staging e marts;
- bucket <project>-raw;
- Artifact Registry data-ingestion;
- serviço Cloud Run data-ingestion;
- repositório Dataform data-models;
- conta dataform-runner e permissões de BigQuery;
- Workflow e Scheduler do Dataform;
- registros e triggers Cloud Build de data_ingestion e data_models;
- permissão para a esteira invocar o Workflow.

5.4 Valores dos ambientes

Variável	Valor versionado	Uso
project_id	gem-dados-lake-stg gem-dados-lake-prd	Projeto do ambiente.
env	stg ou prd	Nomes, labels e branch de deploy.
region	us-central1	Região dos serviços regionais.
bq_location	US	Localização dos datasets BigQuery.
github_owner	gem-dados	Organização dos repositórios.
org_id	809669352691	Organização usada pela tag de governança.

5.5 Esteiras de infraestrutura

5.5.1 Pull request

O arquivo cloudbuild-pr.yaml executa gitleaks, tfsec, terraform fmt -check, terraform validate e terraform plan. O YAML não possui etapa de apply.

5.5.2 Push na branch do ambiente

O arquivo cloudbuild.yaml executa gitleaks, validação, plan e terraform apply. A variável _ENV seleciona envs/stg ou envs/prd.

6 Ingestão - data_ingestion

6.1 Aplicação HTTP

O arquivo src/main.py cria uma aplicação Flask com um registro interno de jobs. As rotas existentes são:

Rota	Método	Comportamento no código
/healthz	GET	Retorna um JSON com status ok.
/run/<job_name>	POST	Procura o job no dicionário JOBS, executa a rotina correspondente e retorna done; nomes ausentes retornam HTTP 404.

6.2 Jobs de ingestão registrados

Nome no endpoint	Script e função executada
ingest	identify_datacamp_csvs.py: identifica dinamicamente os relatórios no Drive por assinatura de colunas.
upload_gcs	upload_parquet_to_gcs.py: converte os relatórios para Parquet e realiza o upload para o GCS.
load_bq	load_gcs_parquet_to_bigquery.py: aterrissa os dados Parquet do GCS nas tabelas raw do BigQuery.

Nome no endpoint	Script e função executada
rotina_sem_duplicatas	rotina_sem_duplicatas_job.py: pipeline integrado e idempotente sem geração de registros duplicados.

O Dockerfile usa Python 3.12 slim, instala as dependências, copia src/, cria o usuário não-root appuser e inicia Gunicorn na porta definida por PORT.

6.3 Variáveis lidas pela aplicação

Variável	Leitura	Uso no código
GCP_PROJECT	Obrigatória	Projeto dos clientes GCS e BigQuery.
RAW_BUCKET	Obrigatória	Bucket da landing zone.
ENVIRONMENT	Padrão stg	Campo env do payload.
BQ_DATASET	Padrão raw	Dataset da tabela carregada.
PORT	Padrão 8080	Porta HTTP do servidor.

6.4 Esteira de deploy

O cloudbuild.yaml executa gitleaks, constrói a imagem Docker, publica a tag SHORT_SHA no Artifact Registry e atualiza o serviço Cloud Run com –no-allow-unauthenticated.

7 Modelagem e Views Analíticas

7.1 Configuração Dataform

O arquivo workflow_settings.yaml registra:

- projeto padrão gem-dados-lake-stg;
- localização BigQuery US;
- dataset padrão staging;
- dataset de assertions dataform_assertions;
- Dataform Core 3.0.0;
- variável env com valor stg.

7.2 Declarações de fontes

Nome Dataform	Origem citada na descrição	Descrição registrada
raw_members	membros_export	Membros e licenças.
raw_summary	resumo_export	Resumo geral da plataforma.
raw_certifications	resumo_por_certificacao_export	Progresso por certificação.

Nome Dataform	Origem citada na descrição	Descrição registrada
raw_content_catalog	catalogo_de_conteudo_export	Catálogo de conteúdos.
raw_course_activity	resumo_por_curso_export	Atividade por curso.
raw_program_activity	resumo_por_programa_export	Atividade por programa ou trilha.
raw_project_activity	resumo_por_projeto_export	Atividade por projeto prático.
raw_skill_assessments	avaliacao_de_habilidades _export	Avaliações de habilidades.
raw_team_history	historico_da_equipe_export	Histórico das equipes.
raw_time_spent	tempo_no_aprendizado_export	Tempo de aprendizado.

Os dez arquivos iniciados por raw_ são declarações Dataform do tipo declaration.

7.3 Camada de staging (definitions/staging)

A camada staging padroniza nomes de colunas, aplica SAFE_CAST para conversão estrita de tipos, normaliza nulos e substitui dados identificáveis pelo código anônimo user_id. Conta com dez modelos:

- stg_members, stg_summary, stg_certifications, stg_content_catalog;
- stg_course_activity, stg_program_activity, stg_project_activity;
- stg_skill_assessments, stg_team_history, stg_time_spent.

7.4 Camada de marts (definitions/marts)

A camada de marts organiza tabelas fato e dimensão para consumo analítico:

- **Dimensões**: dim_usuarios, dim_conteudo;
- **Fatos**: fct_progresso_cursos, fct_progresso_trilhas, fct_atividades_projetos, fct_certificacoes, fct_avaliacoes_habilidades, fct_resumo_usuario, fct_historico_equipe, fct_tempo_aprendizado;
- **Agregações periódicas**: mart_metricas_semanais.

7.5 Testes de qualidade e integridade

São executadas assertions automáticas no Dataform para garantir consistência:

- assert_raw_stg_row_count: validação de contagem de linhas entre raw e staging;
- assert_raw_stg_metrics: validação de consistência e completude métrica.

7.6 Views analíticas no BigQuery (gem-dados-lake-stg.staging)

Para centralizar as regras de negócio e desacoplar o cálculo das ferramentas de visualização, foram criadas views analíticas nativas no BigQuery:

View analítica	Tabela base	Indicadores consolidados
vw_program_activity	stg_program_activity	Taxas de conclusão de assessments, capítulos, cursos e projetos práticos.

7.7 Decisão técnica: migração dos cálculos para SQL

Inicialmente, os cálculos de taxas e proporções estavam sendo implementados na camada semântica do Looker Studio. Seguindo recomendação do Product Owner (PO), essas regras foram migradas para views SQL nativas no BigQuery.

Essa abordagem teve como benefícios:

- centralização e governança das regras de negócio;
- eliminação do acoplamento com a ferramenta de visualização;
- possibilidade de reaproveitamento das métricas por outras ferramentas de BI;
- rastreabilidade direta do cálculo até a camada de staging;
- simplificação da camada de apresentação no Looker Studio.

8 Camada de visualização - Looker Studio

8.1 Conexões e origens do dashboard

O Dashboard de Acompanhamento de Mentorados está hospedado no Looker Studio e conecta diretamente ao dataset staging do projeto gem-dados-lake-stg:

- vw_program_activity: taxas de conclusão de atividades (cursos, capítulos, projetos e assessments);
- stg_certifications: certificações obtidas e status;
- stg_skill_assessment: avaliações e proficiência técnica;
- stg_project_activity: conclusões de projetos práticos.

8.2 Estrutura de páginas e controles

O painel é estruturado em três páginas:

1. **Progresso & Volume**: cards consolidados de conclusões (trilhas, alunos, cursos, projetos, assessments), distribuição por tipo de atividade e taxas de conclusão;
2. **Qualificação**: certificações totais, assessments realizados, desempenho por habilidade e entregas agrupadas por equipe;
3. **Desempenho**: médias de cursos por trilha e taxa de conclusão de cursos por trilha.

Controles dinâmicos de filtro foram aplicados para Trilha (Track), Período (Period) e Nível de Habilidade (Skill Level).

9 Operação registrada

9.1 Fluxo Git descrito nos READMEs

```
git checkout stg
git pull
git checkout -b feat/minha-mudanca
pre-commit run --all-files
git push -u origin feat/minha-mudanca
```

Os READMEs descrevem pull request para stg, validação no ambiente e promoção posterior para main.

9.2 Pontos de observação dos serviços definidos

Componente	Local	Registro gerado pelo código
Cloud Build	Builds do projeto GCP	Etapas de validação, build, push, deploy ou Terraform.
Cloud Run	Logs do serviço	Logs Python do job e respostas HTTP.
Workflows	Workflow dataform-<env>	Compilação e criação da invocação Dataform.
BigQuery	Jobs e Views	Execução de consultas analíticas e atualização de views.
Looker Studio	Relatório de BI	Métricas visuais e logs de conexão com BigQuery.

10 Controles de segurança versionados

- gitleaks nos hooks de pre-commit e nos arquivos Cloud Build;
- tfsec, terraform fmt, validate e plan na esteira de pull request;
- detect-private-key nos hooks de infraestrutura e ingestão;
- arquivos de credencial, state e chaves bloqueados pelos .gitignore;
- Secret Manager para o token da conexão GitHub;
- contas de serviço separadas para Terraform, ingestão, orquestração e execução Dataform;
- bucket raw com prevenção de acesso público;
- Cloud Run implantado sem acesso anônimo;
- container de ingestão executado por usuário não-root;
- anonimização completa dos usuários com uso de user_id em todas as views e telas de BI.

11 Inventário dos componentes

Área	Conteúdo presente
Infraestrutura	Bootstrap, configuração de organização, dois ambientes, dez módulos Terraform (incluindo orquestração) e esteiras de plan/apply.
Ingestão	Aplicação Flask/Cloud Run, quatro jobs registrados em src/jobs/, Dockerfile e esteira de deploy Cloud Run.
Modelagem	Dez declarações raw, modelos de staging (stg_*), marts (dim_*, fct_*), asserções de qualidade, configuração Dataform e esteira de execução.
Views analíticas	View SQL vw_program_activity no BigQuery staging.
Visualização	Dashboard Looker Studio com três páginas (Progresso, Qualificação, Desempenho) e 3 filtros.
Segurança	Anonimização por user_id, gitleaks, tfsec, Bandit/Ruff, hooks pre-commit e IAM em Terraform.

12 Localização dos componentes

Componente	Arquivo, serviço ou diretório
Composição dos ambientes	cloud_iac/envs/stg e cloud_iac/envs/prd
Módulos Terraform	cloud_iac/modules (10 módulos)
Servidor e jobs de ingestão	data_ingestion/src/main.py e data_ingestion/src/jobs/
Imagem do serviço	data_ingestion/Dockerfile
Declarações raw	data_models/definitions/sources
Modelos Dataform	data_models/definitions/staging e data_models/definitions/marts
Views analíticas SQL	BigQuery: gem-dados-lake-stg.staging.vw_program_activity
Camada de BI	Looker Studio: Dashboard de Acompanhamento de Mentorados